

1. Đặc trưng định tuyến mức thấp

$$H_{\leq L_f}(x) = \text{Backbone}_{\leq L_f}(x) \in \mathbb{R}^{T \times d} \quad (1)$$

$$f(x) = \text{MPig}(H_{\leq L_f}(x)) \in \mathbb{R}^d \quad (2)$$

Trong đó:

- x : mẫu đầu vào.
- L_f : số layer đầu được cố định để trích đặc trưng định tuyến.
- T : độ dài chuỗi token.
- d : số chiều hidden state của backbone.
- $H_{\leq L_f}(x)$: hidden states sau L_f layer đầu.
- $\text{MP}(\cdot)$: phép mean-pooling theo chiều token.
- $f(x)$: vector đặc trưng định tuyến mức thấp.

2. Không gian tách task cho analytic router

$$u(x) = \phi(f(x)) \in \mathbb{R}^E \quad (3)$$

$$a_k(x) = u(x)^\top w_k \quad (4)$$

$$p_{\text{RLS}}(k \mid x) = \frac{\exp(a_k(x))}{\sum_{j=1}^K \exp(a_j(x))} \quad (5)$$

Trong đó:

- $\phi(\cdot)$: phép chiếu mở rộng đặc trưng cố định của Any-SSR.
- E : số chiều sau khi mở rộng đặc trưng.
- K : số task/expert đã học.
- $w_k \in \mathbb{R}^E$: vector tham số của analytic router cho task k .
- $a_k(x)$: logit của task k từ analytic router.
- $p_{\text{RLS}}(k \mid x)$: xác suất coarse routing cho task k .

3. Cập nhật analytic router theo RLS

$$\widehat{W}_t^r = \widehat{W}_{t-1}^r + R_t X_t^\top (Y_t - X_t \widehat{W}_{t-1}^r) \quad (6)$$

$$R_t = R_{t-1} - R_{t-1} X_t^\top (I + X_t R_{t-1} X_t^\top)^{-1} X_t R_{t-1} \quad (7)$$

Trong đó:

- t : chỉ số bước cập nhật khi task mới đến.
- $\widehat{W}_t^r \in \mathbb{R}^{E \times K}$: ma trận tham số router sau bước t .
- $X_t \in \mathbb{R}^{n_t \times E}$: ma trận đặc trưng mở rộng của task mới, mỗi hàng là $u(x)$.
- $Y_t \in \mathbb{R}^{n_t \times K}$: ma trận nhãn one-hot theo task.
- n_t : số mẫu ở bước t .
- $R_t \in \mathbb{R}^{E \times E}$: ma trận nghịch đảo hiệu dụng trong RLS.
- I : ma trận đơn vị có kích thước phù hợp.

4. Không gian mật độ mức task cho GMM

$$c_k = \frac{1}{|D_k|} \sum_{x \in D_k} f(x) \quad (8)$$

$$z_k(x) = U_k^\top (f(x) - c_k) \in \mathbb{R}^r \quad (9)$$

Trong đó:

- D_k : tập huấn luyện của task k .
- $|D_k|$: số mẫu của task k .
- $c_k \in \mathbb{R}^d$: tâm đặc trưng của task k trong không gian $f(x)$.
- $U_k \in \mathbb{R}^{d \times r}$: cơ sở hạng thấp của task k .
- r : số chiều của không gian mật độ task-local.
- $z_k(x)$: biểu diễn của mẫu x trong không gian mật độ của task k .

5. Mô hình GMM theo task

$$q_k(z_k(x)) = \sum_{m=1}^{M_k} \pi_{k,m} \mathcal{N}(z_k(x); \mu_{k,m}, \Sigma_{k,m}) \quad (10)$$

$$r_{k,m}(x) = \frac{\pi_{k,m} \mathcal{N}(z_k(x); \mu_{k,m}, \Sigma_{k,m})}{\sum_{j=1}^{M_k} \pi_{k,j} \mathcal{N}(z_k(x); \mu_{k,j}, \Sigma_{k,j})} \quad (11)$$

$$d_k(x) = \log q_k(z_k(x)) \quad (12)$$

Trong đó:

- M_k : số Gaussian component của task k .
- $\pi_{k,m}$: trọng số của component m trong task k , với $\pi_{k,m} \geq 0$ và $\sum_{m=1}^{M_k} \pi_{k,m} = 1$.
- $\mu_{k,m} \in \mathbb{R}^r$: vector trung bình của component m .
- $\Sigma_{k,m} \in \mathbb{R}^{r \times r}$: ma trận hiệp phương sai của component m .
- $q_k(\cdot)$: mật độ GMM của task k .
- $r_{k,m}(x)$: posterior mềm của component m cho mẫu x .
- $d_k(x)$: log-density score của task k .

6. Chuẩn hóa điểm số từ hai nhánh router

$$\hat{a}_k(x) = \frac{a_k(x) - \mu_k^{(a)}}{\sigma_k^{(a)} + \varepsilon} \quad (13)$$

$$\hat{d}_k(x) = \frac{d_k(x) - \mu_k^{(d)}}{\sigma_k^{(d)} + \varepsilon} \quad (14)$$

Trong đó:

- $\mu_k^{(a)}, \sigma_k^{(a)}$: trung bình và độ lệch chuẩn của logit a_k trên tập hiệu chỉnh của task k .
- $\mu_k^{(d)}, \sigma_k^{(d)}$: trung bình và độ lệch chuẩn của log-density d_k trên tập hiệu chỉnh của task k .
- $\varepsilon > 0$: hằng số nhỏ để tránh chia cho 0.
- $\hat{a}_k(x)$: analytic score đã chuẩn hóa.
- $\hat{d}_k(x)$: density score đã chuẩn hóa.

7. Trộn thích nghi theo độ mơ hồ của router

$$m(x) = \hat{a}_{(1)}(x) - \hat{a}_{(2)}(x) \quad (15)$$

$$\gamma(x) = \sigma(\eta(\tau_m - m(x))) \quad (16)$$

$$g_k(x) = (1 - \gamma(x))\hat{a}_k(x) + \gamma(x)\hat{d}_k(x) \quad (17)$$

Trong đó:

- $\hat{a}_{(1)}(x), \hat{a}_{(2)}(x)$: analytic scores lớn nhất và lớn thứ hai trên tất cả các task.
- $m(x)$: biên độ phân tách giữa hai task đứng đầu theo analytic router.
- $\sigma(\cdot)$: hàm sigmoid.
- $\eta > 0$: hệ số độ dốc của sigmoid.
- τ_m : ngưỡng biên độ để xác định mức mơ hồ.
- $\gamma(x) \in (0, 1)$: hệ số trộn thích nghi giữa analytic score và density score.
- $g_k(x)$: gating logit cuối cùng của task k .

8. Soft routing vector

$$\alpha_k(x) = \frac{\exp(g_k(x)/\tau)}{\sum_{j=1}^K \exp(g_j(x)/\tau)} \quad (18)$$

$$\boldsymbol{\alpha}(x) = [\alpha_1(x), \dots, \alpha_K(x)]^\top \in \mathbb{R}^K \quad (19)$$

Trong đó:

- $\tau > 0$: temperature của softmax khi định tuyến mềm.
- $\alpha_k(x)$: trọng số mềm của task/expert k cho mẫu x .
- $\boldsymbol{\alpha}(x)$: vector soft routing trên toàn bộ K task/expert.

9. Trộn expert ở mức phân phối đầu ra

$$p_k(y_t \mid x, y_{<t}) = \text{Expert}_k(x, y_{<t}) \quad (20)$$

$$p_{\text{mix}}(y_t \mid x, y_{<t}) = \sum_{k=1}^K \alpha_k(x) p_k(y_t \mid x, y_{<t}) \quad (21)$$

Trong đó:

- y_t : token đầu ra tại bước sinh thứ t .
- $y_{<t}$: chuỗi token đầu ra trước bước t .
- Expert_k : expert/adapter của task k .
- $p_k(\cdot)$: phân phối đầu ra của expert k .
- $p_{\text{mix}}(\cdot)$: phân phối đầu ra sau khi trộn mềm các expert.